项目1：某生活服务数仓建设

项目背景

某头部生活服务平台为构建内容业务，覆盖多城多业态（餐饮/外卖/酒旅等），通过内容营销方式提升用户消费转化、激活商户经营活力，是集团xx年第二增长曲线核心战略。

业务初期数据源分散（超过8个终端来源）、跨BP开发模式导致数据口径混乱（核心指标冗余明显）与存储成本激增（埋点数据日增TB级）的核心痛点。

急需构建高效稳定、低成本的离线数仓，支撑直播规划、流量漏斗分析、用户行为归因等核心场景。

主要职责

1. **指标规范与体系建设**
   - 基于AARRR模型拆解用户生命周期与流量漏斗分析场景，划分基础原子指标（如PV/UV/停留时长）与复合指标（如流量-成交转化率），通过指标血缘分析消除冗余计算口径（收敛相似指标33类）。
   - 建立指标分层策略：动态层承载短期AB实验指标（如弹窗CTR），稳定层固化业务常用聚合维度（按开播时段/商品类目/用户分层聚合流量分布）。
2. **流量域数仓架构设计**
   - 采用维度建模构建流量域，明确分层规范：
     - DWD层构建标准化埋点事件模型（规范401个埋点字段定义），通过“事件ID+用户ID+时间粒度”主键保障数据唯一性；
     - DWS层预聚合核心场景数据（如10分钟级流量热力图），采用列存+Bitmap索引降低高频维度钻取耗时（例如用户分群查询提速至毫秒级）。
3. **模型设计与治理闭环**
   - 基于流量数据**时序递增、高时效性**特点，构建**增量事实表+全量维度表**组合模式：
     - 增量层采用**Parquet列式存储+Z-Order排序键优化**（按user_id,event_time聚簇），使高频查询场景（如用户30天行为路径）存储扫描量减少62%；
     - 预聚合层实施**多维立方体降维策略**，对50+核心维度组合构建二级聚合汇总表，压缩可枚举维度组合冗余度达70%
   - 建立**模型生命周期管理机制**：
     - 上线前通过**阈值规则引擎**自动校验模型字段覆盖率（如埋点字段缺失率<0.5%）、主键唯一性（数据重复率<0.01%）；
     - 运行期搭建**数据健康度评分卡**，从时效性（SLA达成率）、资源消耗（CPU/Mem波动率）、调用热度（下游访问占比）三维度自动分级预警。

成果亮点

- **质量层面**：核心指标（GTV/UV价值）定义一致率从63%提升至98%，线上数据异常平均定位时长从6小时缩短至40分钟；
- **效率层面**：流量主题基础数据层T+1产出时间提前3.2小时（9:30→6:10），DWS层预聚合模型支撑即席查询响应时间<1.2秒（同比提升4倍）；
- **成本层面**：日志类数据存储成本下降42%（月均节省210万），模型冗余度降低后日均计算资源消耗减少26%。

项目2：用户画像优化升级

项目背景

为了支撑营收超千万级业务活动。数据团队在精准营销、广告投放等场景提供高可用用户标签服务。目前画像平台全Redis存储导致成本激增（月均存储费用超50万）、标签开发缺乏血缘管理（30%标签无人维护），人群包功能缺失制约运营效率。急需重构画像存储架构，优化数据结构并引入生命周期管理，扩展人群包服务能力。

主要职责

1. 牵头将**3000+离线标签**按行为、属性等主题重组，设计分层BitMap方案压缩高基数标签存储空间。
2. 基于ClickHouse搭建人群包服务引擎（支持交/并/差集运算），实现实时圈选与离线分析场景全覆盖。
3. 构建端到端监控体系，覆盖标签产出延迟、数据分布异常等15+质量维度。

成果亮点

1. 存储成本下降**42%**（Redis集群规模从200节点缩减至115节点，日均计算资源消耗降低35%）。
2. 人群包功能上线后支撑**15+营销活动**，单次活动**人群构建效率提升60%**（小时级→分钟级）
3. 标签质量监控覆盖率达**100%**，SLA从**92%提升至99.8%**，下线**650+无效血缘标签释放存储冗余。

项目3： AB实验数据链路建设

项目背景

平台通过科学化AB实验工具赋能业务团队快速验证产品迭代与策略优化效果，推动数据驱动的精准决策，降低试错成本。累计支持日均万级流量的策略验证场景，成为多个业务线的核心优化工具。

原有实验流程依赖人工圈选流量与分析，实验周期长（平均3-5天）、资源浪费显著；分层流量控制能力不足，多维度叠加实验场景下置信度低（误判率超15%），无法支持复杂业务假设验证。

急需构建高并发、低延迟、强置信度的AB实验数据链路，实现从流量分配、指标计算到效果分析的全流程自动化。

主要职责

1. **实验指标体系设计**：主导必看指标（DAU、转化率）、业务指标（点击率、GTV）、自定义指标等分层架构，通过Hive离线加工 + ClickHouse实时预聚合实现多时间粒度（分钟/小时/天级）的T+1指标产出，数据质量经100+规则校验（一致性误差<0.1%）。
2. **自动化配置与保障**：基于InfluxDB+Hadoop构建指标血缘监控体系，看板配置支持业务方自助指标分析（如延迟转化漏斗），配置耗时从小时级压缩至5分钟，人力成本降低50%。
3. **统计检验优化**：引入Bootstrap检验增强小流量实验（<5%流量占比）的置信度，优化DID检验消除时间偏差，误判率从15%降低至5%，实验结论采纳率提升40%。

成果亮点

1. **效率提升**：实验全流程耗时从5天压缩至6小时，平台日均承载实验数从10增至500+，支持双层流量分桶并发实验场景。
2. **成本节约**：通过自动化配置与预计算模型，单实验分析人力成本降低4人日/月，年节省人力成本达480人日。
3. **决策价值**：实验误判率下降67%，策略迭代周期提速3倍，某核心场景GTV实验推动交易额环比增长12%，成为业务准迭代标配工具。

项目4：财务集市设计

项目背景

该项目聚焦于为高复杂度的xx业务构建离线财务数据底座，旨在支撑多维度财务分析、精准对账及合规入账等需求，满足集团级财务风险管控与战略决策诉求。

随着业务快速增长，财务面临数据口径分散、业务链路复杂化带来的入账与对账风险，同时历史脚本冗余严重导致维护成本激增，跨系统不一致性进一步加剧人力投入与时效压力。

急需通过整合多源业务数据，构建统一的财务主题集市，实现全链路财务指标规范化管理。

主要职责

1. **业财口径统一与标准化**：联合财务、产研部门梳理xx业务资金流转链路，基于会计准则对齐业务侧入账规则与分析口径，沉淀50+核心指标至统一指标平台，消除跨部门协作分歧。

2. **分层模型设计与开发**：聚焦核心资产业务（如虚拟货币交易与卖家收益），在DWD层设计15+订单级事实表厘清充退、消费、计提等关键原子事件；在DWM层构建主播收入、用户消费等5+主题宽表，聚合50+核心指标实现多粒度财务视角覆盖。
3. **数据治理体系搭建**：建立新场景接入SOP流程与数据质量监控规则库，完成下游10+核心看板与报表迁移重构，封装标准化数据服务接口降低使用门槛。

成果亮点

1. **风险可控性提升**：月初对账人力成本从 **3人日/月** 降至 **0.5人日/月**，关键链路数据一致性达 **99.99%**；
2. **效率显著优化**：脚本冗余逻辑减少 **70%**，跨系统指标加工时效提升 **60%**（原T+3缩短至T+1）；
3. **复用性增强**：核心模型覆盖 **80%+** 的财务分析场景，标准化接口使下游数据获取效率提升 **50%**。

项目5：数据治理

项目背景

- **业务价值**：支撑业务高速迭代下的精细化运营诉求，确保数据资产成为可复用、可持续增长的决策资源；推动跨部门数据高效流通，为智能分析、实时风控、用户增长等核心场景提供可靠性保障。
- **痛点问题**：随着数据量呈指数级增长，存在字段重复冗余（*如20+同名异构指标*）、模型血缘缺失（依赖链断裂率＞30%）、存储成本激增（年增长超200%）等问题，导致数据可信度下降、开发协同效率不足、隐性运维成本飙升。
- **核心目标**：构建涵盖模型治理、质量监控、成本优化的一体化数据治理体系，实现数据资产"可见、可用、可信"的闭环管理。

主要职责

1. **模型治理体系设计**
   - 主导烟囱模型拆解与分层建模规范设计，针对口径冲突、反向依赖等问题，构建跨主题域模型穿透检查机制，推动整体复用率从48%提升至89%；
   - 落地字段级命名与注释规范（新增300+词根库/术语表），消除30%无效字段，修复4,200+表缺失注释问题。
2. **元数据地图建设**
   - 基于DAG血缘链路解析，搭建覆盖表-字段-任务三层血缘的追踪系统，实现90%核心链路可视化（日均减少20+人天的排查成本）；
   - 通过ETL任务血缘反哺计算资源分配优化（如识别低频高耗任务，减少15%重复计算冗余）。

3. **跨部门协同治理**
   - 联动数据安全团队设计分级分类标签体系（覆盖12万+字段脱敏规则）；
   - 与成本运营团队共建治理看板（集成存储/计算治理策略），驱动业务线形成健康分跟踪机制。

成果亮点

1. **成本治理**：通过冷热分级（Tiering）、压缩算法优化（ORC+ZSTD），节省存储19.2PB（较基线下降41%），计算资源日均消耗降低4TB（P99任务耗时下降65%）；
2. **效能提升**：标准化分层模型后开发迭代周期缩短42%，血缘地图覆盖率达88%后运维排查PMV减少80%；
3. **质量兜底**：构建200+指标监控规则（包括空值率/波动阈值/一致性校验），核心链路SLA从92%提升至99.7%；
4. **行业影响**：治理方法论输出3项技术专利，相关实践入选DataOps联盟年度标杆案例。